Predicción de Quiebra Empresarial con Aprendizaje de Máquina: Dataset Taiwanese Bankruptcy

Wanerge Almanza Velasquez, Jhon Fredy Hoyos Cardenas, Miguel Angel Castiblanco Florez
Modelos y Simulación II, Universidad de Antioquia
Medellín, Colombia

I. Descripción del Problema

I-A. Contexto del Problema y Justificación de Machine Learning

La insolvencia financiera o quiebra empresarial constituye un fenómeno de alto impacto macroeconómico y sistémico. La incapacidad sobrevenida de una firma para solventar sus compromisos de deuda desencadena pérdidas severas para accionistas, entidades bancarias, acreedores comerciales y el mercado laboral. En consecuencia, el diseño de sistemas de alerta temprana para la detección predictiva del estrés financiero representa una necesidad operativa fundamental para la mitigación del riesgo de crédito.

Tradicionalmente, la modelación de la bancarrota descansó sobre enfoques estadísticos univariados y multivariados lineales, tales como el modelo pionero Z-Score de Altman (1968) basado en Análisis Discriminante Lineal (LDA) y el modelo O-Score de Ohlson (1980) fundamentado en Regresión Logística. Pese a su relevancia histórica, dichos métodos adolecen de limitaciones estructurales en entornos corporativos modernos:

1. **Supuestos distributivos restrictivos:** Asumen normalidad multivariada y linealidad en las fronteras de separación, premisas incompatibles con las colas pesadas y asimetrías empíricas de los ratios contables.
2. **Incapacidad ante interacciones de alta dimensión:** La insolvencia emerge de complejas interacciones no lineales entre apalancamiento, rotación de activos y restricciones de liquidez a corto plazo.
3. **Ineficacia ante costos asimétricos:** Maximizan la exactitud global sin ponderar el perjuicio desproporcionado derivado de los Falsos Negativos (clasificar erróneamente a una firma quebrada como solvente).

Bajo este panorama, el empleo de técnicas de Aprendizaje de Máquina (*Machine Learning* - ML) se justifica plenamente. Los modelos basados en ensambles de árboles, métodos de kernel no lineales y redes neuronales artificiales permiten aprender representaciones complejas sin supuestos distributivos restrictivos, acoplando esquemas de remuestreo guiado y regularización que gestionan eficazmente el desbalance de clases y la asimetría de costos.

I-B. Descripción y Composición del Conjunto de Datos

La investigación se fundamenta en el conjunto de datos de referencia *Taiwanese Bankruptcy Prediction Data Set* (UCI ID: 572), recopilado por el *Taiwan Economic Journal* (TEJ) entre los años 1999 y 2009 bajo la normativa bursátil de la Bolsa de Taiwán (*Taiwan Stock Exchange* - TWSE).

- **Volumen muestral:** $N = 6{,}819$ observaciones empresariales auditadas.
- **Desbalance extremo de clases:** La variable objetivo (`Bankrupt`) presenta 6,599 registros de firmas solventes (clase mayoritaria, 96.774 %) y tan solo 220 registros de firmas en quiebra (clase minoritaria, 3.226 %), conformando una proporción aproximada de 30:1.
- **Dimensiones y significado contable:** Cuenta con 96 columnas (95 características explicativas y la etiqueta de salida). Las variables capturan dimensiones financieras cruciales: *Rentabilidad* (ROA en diversas variantes, margen bruto y operativo), *Solvencia y Estructura de Capital* (razón de endeudamiento, pasivo sobre patrimonio), *Liquidez* (razón corriente, razón rápida), *Flujo de Caja* (flujo de caja sobre activo total y ventas), *Eficiencia Operativa* (rotación de inventario y cuentas por cobrar) y *Crecimiento* (crecimiento de activo y utilidad neta).
- **Valores faltantes:** No existen registros nulos ni valores faltantes (0 NaNs), prescindiendo de técnicas de imputación.
- **Codificación:** 93 variables cuantitativas continuas normalizadas en origen, dos variables discretas indicadoras binarias (`Liability-Assets Flag` y `Net Income Flag`) y la variable dependiente binaria $y_i \in \{0, 1\}$.

I-C. Análisis Exploratorio de los Datos

El análisis exploratorio, reproducible en el notebook del repositorio, se centró en tres aspectos que condicionan el diseño experimental. Primero, el desbalance de clases descrito previamente.

Segundo, la redundancia entre variables: varias razones financieras miden prácticamente lo mismo, y la literatura reporta numerosos pares con correlación de Pearson superior a 0.9, por ejemplo, entre variantes del ROA o del valor por acción [2], [3]. En este dataset se confirmó la presencia de características altamente correlacionadas, lo que motiva evaluar técnicas de reducción de dimensionalidad.

Tercero, la asimetría de la distribución de varias razones (p. ej., *Equity to Liability*) [2]. Esta condición extrema se verificó en la distribución de los datos, lo que hace necesario aplicar un escalado robusto o transformaciones logarítmicas. Además, se confirmó la ausencia total de valores nulos y de filas duplicadas en los registros.

I-D. Configuración y Paradigma de Aprendizaje Seleccionado

Se determinó como apropiado el paradigma de **Aprendizaje Supervisado** en configuración de **Clasificación Binaria con Clases Desbalanceadas**. Dicha elección se sustenta en:

1. La existencia de etiquetas verdaderas auditadas ($y_i \in \{0, 1\}$) proporcionadas por la autoridad bursátil para cada vector de características $\mathbf{x}_i \in \mathbb{R}^{95}$, formulando el objetivo como la minimización del riesgo empírico ponderado por costos.
2. La inadecuación de enfoques no supervisados de conglomerados (*clustering*), dado que las empresas en quiebra no conforman agrupaciones compactas aisladas en el espacio euclidiano, sino instancias periféricas solapadas en fronteras de decisión ruidosas.

II. Estado del Arte

La literatura especializada en predicción de quiebra ha evolucionado hacia esquemas híbridos que combinan remuestreo algorítmico, selección de características y ensambles de aprendizaje. Se seleccionaron cuatro investigaciones indexadas en revistas de primer nivel que abordan el dataset de Taiwán:

1) Liang et al. (2016) [1]: Evaluaron un paradigma supervisado emparejado (239 firmas en quiebra y 239 solventes) mediante validación cruzada de 10 pliegues. Compararon SVM, KNN, CART, MLP y Naive Bayes, aplicando filtros (*Stepwise Discriminant Analysis* - SDA, SLR, t-test) y envolturas (GA, RFE). Demostraron la superioridad de SVM sobre razones financieras frente a gobernanza corporativa (79.1 % vs. 67.9 %). La combinación de ambas familias con selección SDA alcanzó una exactitud de 81.3 % y minimizó el costo de mala clasificación asimétrico ($MC = C(I)FN + C(II)FP$).

2) Wang y Liu (2021) [2]: Abordaron el desbalance natural (3.2 % quiebras) empleando validación cruzada estratificada de 10 pliegues repetida 3 veces (30 ejecuciones) en un *pipeline* estricto sin fuga de datos (*data leakage*). Compararon técnicas de submuestreo (*Tomek Links*, ENN, RENN, OSS, NCR y CMUT) sobre nueve modelos. Justificaron formalmente la métrica F_2 ($\beta = 2$) para priorizar la Sensibilidad ante el costo crediticio:

$$F_2 = 5 \times \frac{\text{Precision} \times \text{Recall}}{4 \times \text{Precision} + \text{Recall}} \tag{1}$$

Gaussian Naive Bayes tras *Edited Nearest Neighbors* (ENN) alcanzó el mejor desempeño global ($F_2 = 0{,}423$), seguido de LDA ($F_2 = 0{,}368$).

3) Pham et al. (2025) [3]: Propusieron un esquema híbrido que integró sobremuestreo SMOTE-ENN con optimización metaheurística por Enjambre de Partículas Binarias (BPSO), reduciendo la dimensión a 34 variables antes de entrenar SVM, Random Forest y Redes Neuronales (ANN). Reportaron un F_1-score de 98.5 % con ANN y 97.8 % con Random Forest; no obstante, la literatura advierte que tales resultados reflejan sobreestimación por fuga de datos al aplicar remuestreo previo a la partición de prueba.

4) Azad et al. (2026) [4]: Introdujeron un marco de destilación de conocimiento supervisado (APEX-DEFT) que comprime un ensamble *stacking* (LightGBM, XGBoost, Bayesian Ridge) en un modelo ligero de *Histogram Gradient Boosting* (HGB) regularizado con LASSO e Información Mutua. Mediante validación estratificada de 5 pliegues y métricas robustas como el Coeficiente de Correlación de Matthews (MCC):

$$\text{MCC} = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}} \tag{2}$$

y el Coeficiente Kappa de Cohen ($\kappa = \frac{P_o - P_e}{1 - P_e}$), el modelo estudiante retuvo un desempeño competitivo ($F_1 = 69{,}05\,\%$, Recall = 81.40 %, AUC = 93.17 %) con una reducción computacional superior al 80 % (1.55 s), incorporando explicabilidad mediante SHAP y LIME.

Referencias

[1] D. Liang, C.-C. Lu, C.-F. Tsai, and G.-A. Shih, "Financial ratios and corporate governance indicators in bankruptcy prediction: A comprehensive study," *European Journal of Operational Research*, vol. 252, no. 2, pp. 561–572, 2016.

[2] H. Wang and X. Liu, "Undersampling bankruptcy prediction: Taiwan bankruptcy data," *PLOS ONE*, vol. 16, no. 7, p. e0254030, 2021.

[3] H. V. Pham *et al.*, "Comprehensive Evaluation of Bankruptcy Prediction in Taiwanese Firms Using Multiple Machine Learning Models," *International Journal of Technology*, vol. 16, no. 1, pp. 289–309, 2025.

[4] M. A. K. Azad *et al.*, "Predicting corporate bankruptcy through a scalable and interpretable knowledge distillation framework," *Discover Artificial Intelligence*, vol. 6, no. 1, art. 1186, 2026.

Cuadro I
MATRIZ COMPARATIVA DE INVESTIGACIONES EN EL ESTADO DEL ARTE (DATASET TEJ TAIWÁN)

Criterio	**Liang et al. (2016) [1]**	**Wang & Liu (2021) [2]**	**Pham et al. (2025) [3]**	**Azad et al. (2026) [4]**
Revista	*EJOR* (Elsevier, Q1)	*PLOS ONE* (PLOS, Q1)	*Int. J. of Technology* (Q2)	*Discover AI* (Springer Nature)
Paradigma	Supervisado (Binario emparejado)	Supervisado (Submuestreo)	Supervisado (Flujo híbrido)	Supervisado (Destilación de Conocimiento)
Modelos ML	SVM, KNN, CART, MLP, Naive Bayes	NB, LDA, NN, XGB, KNN, LR, RF, SVM	SVM (4 kernels), RF, ANN	Profesor: Stacking $\rightarrow$ Estudiante: Hist-GB
Preprocesamiento	Filtros SDA, SLR, t-test; GA, RFE	Submuestreo TL, ENN, RENN, OSS, NCR, CMUT	SMOTE-Tomek, SMOTE-ENN; BPSO (34 vars)	LASSO + Info Mutua; SMOTE-ENN, ADASYN
Validación	10-fold CV (1:1, 478 casos). Wilcoxon	Repeated Stratified 10-fold CV (30 runs)	Train/Test split con HPO Random Search	Stratified 5-fold CV (medición latencia)
Métricas	Accuracy, Error Tipo I/II, ROC, Costo MC	Accuracy, Precision, Recall, F_1, F_2-Score	Accuracy, Precision, Recall, F_1-score	Accuracy, Recall, F_1, AUC, MCC, Kappa, Tiempo
Resultados	SVM + SDA en FR+CGI: Acc = 81.3 %	Naive Bayes + ENN: $F_2 = 0{,}423$; LDA: 0.368	ANN + SMOTE-ENN + BPSO: $F_1 = 98{,}5\,\%$	Estudiante HGB: $F_1 = 69{,}05\,\%$, Rec = 81.4 % (1.55 s)